



I308 - Visión Artificial

**Trabajo Práctico 1:
Panorámicas**

Joaquín Szterensus y Damián Distefano

12 de mayo de 2025

Ingeniería en Inteligencia Artificial

Resumen

En este trabajo se implementa un pipeline de visión por computadora para la construcción de imágenes panorámicas a partir de múltiples vistas parciales de una misma escena. Se describen los métodos utilizados para la detección, descripción y asociación de características visuales, la estimación de homografías y la composición final de la panorámica.

1. Introducción

El objetivo de este trabajo es generar imágenes panorámicas a partir de conjuntos de imágenes tomadas con un 30–50 % de solapamiento. El desafío consiste en detectar puntos de interés robustos en cada imagen, establecer correspondencias confiables entre ellas y estimar las transformaciones geométricas que permiten alinear las imágenes sobre una misma referencia.

Durante el desarrollo se utilizaron inicialmente los conjuntos de imágenes provistos por la cátedra, correspondientes al campus de UDESA con el fin de probar y depurar las distintas etapas del pipeline. Sin embargo, para el presente informe se trabajó únicamente con un conjunto de fotografías tomadas por nosotros mismos de otro edificio de UDESA.

En este segundo conjunto, las vistas parciales incluían distintos edificios y espacios del predio. Como en el caso de prueba, se seleccionó una imagen central como ancla, sobre la cual se alinearon las imágenes restantes para reconstruir la panorámica. De esta manera, el experimento permitió evaluar la robustez del método en un escenario propio y obtener como resultado final una panorámica generada a partir de nuestras propias capturas.

2. Métodos

El proceso completo se estructuró como un pipeline. En primer lugar se detectaron y describieron características locales en cada imagen. Posteriormente, se aplicó una etapa de supresión adaptativa para mejorar la distribución espacial de los puntos detectados. Luego se realizó la asociación de correspondencias entre imágenes adyacentes, y a partir de estas correspondencias se estimaron homografías tanto mediante selección manual de puntos como utilizando el esquema robusto de RANSAC. Finalmente, las imágenes fueron alineadas y compuestas para formar la panorámica.

2.1. Detección y descripción de características

La detección de puntos de interés se realizó con el algoritmo SIFT (Scale-Invariant Feature Transform), que busca puntos invariantes a escala, rotación y cambios moderados de iluminación. El método consta de cuatro pasos principales.

Primero, se construye una pirámide de escala con filtros Gaussianos y se calculan diferencias de Gaussianas

$$D(x, y, \sigma) = (G(x, y, k\sigma) - G(x, y, \sigma)) * I(x, y),$$

donde los máximos y mínimos locales en D definen candidatos a keypoints.

Luego, los puntos se refinan eliminando aquellos de bajo contraste o ubicados en bordes inestables.

Cada keypoint recibe una orientación calculada a partir del gradiente de la imagen en su vecindad

$$m(x, y) = \sqrt{\left(\frac{\partial I}{\partial x}\right)^2 + \left(\frac{\partial I}{\partial y}\right)^2}, \quad (1)$$

$$\theta(x, y) = \arctan\left(\frac{\partial I}{\partial y} / \frac{\partial I}{\partial x}\right). \quad (2)$$

Finalmente, se construye un descriptor de 128 dimensiones tomando una región 16×16 en torno al punto, dividiéndola en bloques de 4×4 y acumulando histogramas de gradientes en 8 direcciones.

De esta manera, cada imagen queda representada por un conjunto de keypoints con posición, escala, orientación y un descriptor robusto de 128 valores, que constituyen la base para el emparejamiento posterior.

2.2. Supresión de no máximos adaptativa

La cantidad de puntos detectados por SIFT puede ser excesiva y estar concentrada en zonas pequeñas de la imagen. Para mejorar la representatividad espacial se aplicó el algoritmo ANMS (Adaptive Non-Maximal Suppression), que selecciona un número fijo N de keypoints favoreciendo aquellos que son fuertes y, al mismo tiempo, están más aislados.

Sea el conjunto de keypoints $\{p_i\}$ con respuestas asociadas r_i . Para cada punto se define un radio de supresión

$$R_i = \min_{j:r_j > r_i} \|p_i - p_j\|,$$

que mide la distancia mínima a otro punto más fuerte. Los keypoints más interesantes son los que maximizan R_i , ya que poseen alta respuesta y se encuentran distribuidos de manera uniforme en la imagen.

Finalmente se seleccionan los N puntos con mayor R_i , lo que reduce la redundancia y mantiene un conjunto más equilibrado de características.

2.3. Asociación de características

La asociación entre pares de imágenes se resolvió mediante el emparejamiento de descriptores obtenidos con SIFT. Para cada descriptor en la imagen fuente se busca su vecino más cercano en la imagen destino,

calculando la distancia euclídea entre vectores de 128 dimensiones

$$d(\mathbf{f}_i, \mathbf{f}_j) = \|\mathbf{f}_i - \mathbf{f}_j\|_2.$$

Con el fin de incrementar la robustez se aplicaron dos filtros. En primer lugar, la verificación cruzada (*cross-check*), que requiere que la correspondencia sea mutua, es decir, que f_i sea el mejor vecino de f_j y, a la vez, f_j sea el mejor vecino de f_i .

En segundo lugar, el criterio de Lowe, que establece que un match se acepta solo si el mejor vecino es significativamente más cercano que el segundo mejor. Si d_1 y d_2 representan las distancias al primer y segundo vecino respectivamente, la condición es

$$\frac{d_1}{d_2} < \tau,$$

Este criterio descarta correspondencias ambiguas y mejora la precisión del emparejamiento.

2.4. Estimación de homografías

Una homografía es una transformación proyectiva que relaciona dos vistas de un mismo plano. En coordenadas homogéneas se cumple

$$\mathbf{x}' \sim H\mathbf{x}, \quad H \in \mathbb{R}^{3 \times 3},$$

donde $\mathbf{x}$ y $\mathbf{x}'$ son puntos correspondientes en dos imágenes.

DLT (Direct Linear Transformation). Dado un conjunto de correspondencias $\{(\mathbf{x}_i, \mathbf{x}'_i)\}$ con $N \geq 4$, cada par aporta dos ecuaciones lineales que pueden organizarse en un sistema

$$A\mathbf{h} = 0,$$

donde $\mathbf{h}$ es el vector con los nueve parámetros de H . La solución se obtiene con descomposición en valores singulares (SVD).

RANSAC. En la práctica, muchas correspondencias son erróneas (*outliers*). RANSAC permite estimar H de forma robusta seleccionando al azar subconjuntos de cuatro puntos, calculando una homografía

candidata con DLT y midiendo el error de reproyección

$$e_i = \|\mathbf{x}'_i - H\mathbf{x}_i\|^2.$$

Si $e_i < t$ (con t un umbral), la correspondencia se considera un *inlier*, de lo contrario es un *outlier*. Tras varias iteraciones se conserva la homografía que maximiza la cantidad de inliers, y finalmente se recalcula H usando solo esas correspondencias consistentes.

2.5. Construcción de la panorámica

Con las homografías calculadas, las imágenes laterales fueron alineadas con la imagen ancla mediante warping, es decir, proyectando cada píxel de la imagen en el plano de referencia utilizando la transformación H . Una vez obtenida la alineación, fue necesario aplicar un proceso de blending para suavizar las transiciones en las zonas de solapamiento.

3. Resultados

En esta sección se presentarán los resultados obtenidos en cada etapa: detección de características, matches entre imágenes, homografías estimadas y panorámicas finales. Se incluirán capturas parciales y finales del conjunto de imágenes propuesto por nosotros, tomadas en el campus universitario.

El conjunto elegido corresponde a una vista del campus en un día soleado. La imagen central fue seleccionada como ancla para construir la panorámica.



Figura 1: Conjunto de imágenes propio, tomado en el campus UDESA. La imagen central (C) se utilizó como ancla.

3.1. Detección y selección de puntos clave

La detección de puntos de interés se realizó con SIFT, que devuelve miles de keypoints distribuidos en toda la imagen. Sin embargo, esta cantidad excesiva de puntos tiende a concentrarse en áreas muy texturadas, generando redundancias.

Para resolverlo aplicamos *Adaptive Non-Maximal Suppression* (ANMS), reduciendo la cantidad de keypoints y quedándonos con los 2500 más representativos y mejor distribuidos espacialmente. Esto produce una representación más uniforme de cada imagen y facilita el matching posterior.




Figura 2: Keypoints detectados con SIFT en el conjunto propio.



Figura 3: Keypoints seleccionados mediante ANMS (2500 puntos).

3.2. Matching de características

Para establecer correspondencias entre descriptores utilizamos `BFMatcher` con norma L2, adecuada para descriptores SIFT. Los matches se filtraron con dos criterios: verificación cruzada (conservando solo correspondencias mutuas) y el ratio test de Lowe con $\tau = 0,55$. De esta forma obtuvimos un conjunto final de correspondencias confiable y consistente.

En las Figuras 4 y 5 se muestran los pares de vistas enfrentadas, donde los puntos conectados corresponden a matches válidos. Puede observarse que la mayoría de las correspondencias unen regiones coherentes entre imágenes.




Figura 4: Matching Izquierda–Centro.




Figura 5: Matching Derecha–Centro.

3.3. Estimación de homografías con RANSAC

A partir de las correspondencias obtenidas se estimaron homografías de manera robusta mediante RANSAC. En cada iteración se muestreó aleatoriamente un subconjunto mínimo de correspondencias, se estimó una homografía candidata a partir de ese subconjunto y se evaluó su calidad midiendo el error de reproyección sobre todas las correspondencias. Aquellas con error menor a un umbral de 4 píxeles se consideraron *inliers*, mientras que el resto se descartaron como *outliers*.

Se retuvo el modelo que maximiza la cantidad de *inliers* y, finalmente, se re-estimó la homografía empleando únicamente dichas correspondencias coherentes para obtener un resultado más estable. Las Figuras 6 y 7 muestran los *inliers* (en verde) y *outliers* (en rojo) para los pares Izquierda–Centro y Derecha–Centro, respectivamente.



Figura 6: RANSAC Izquierda–Centro.




Figura 7: RANSAC Derecha–Centro.

3.4. Warping

Para definir los límites del lienzo se calculo primero las cuatro esquinas de cada imagen en sus coordenadas propias y se las transformo al plano de la imagen central mediante las homografías. Junto con las esquinas de la imagen central se formó el conjunto `all_corners`. A partir de ese conjunto obtuvimos las coordenadas $x_{\min}$, $y_{\min}$, $x_{\max}$, $y_{\max}$. El tamaño de la nueva imagen queda definido por $\text{width} = x_{\max} - x_{\min}$ y $\text{height} = y_{\max} - y_{\min}$.

Después de warpear las imágenes hicimos un paso para igualar el brillo y el color de las imágenes laterales con la central. En las zonas donde se superponen, ajustamos la intensidad de cada canal de color de las imágenes laterales para que se parezcan más a la central. Este paso se realizó para evitar que en la panorámica final se noten saltos de luz o de color en las costuras y lograr una transición más suave. Una vez hecho este ajuste recalculamos las máscaras porque algunos píxeles pueden haber cambiado.

Luego generamos mapas de peso para cada imagen a partir de sus máscaras usando `make_weight_map`, que crea un degradado suave desde los bordes hacia el interior. Esto nos permitió que las transiciones entre imágenes sean progresivas en vez de abruptas. En las zonas donde sólo hay una imagen presente le dimos peso completo para que no quede atenuada. Con los tres mapas de peso y las imágenes warpeadas convertidas a `float32` hicimos una combinación ponderada: cada píxel de la panorámica se calcula como la media de los valores de las imágenes, ponderada según su mapa de peso. Así conseguimos que en las áreas de solapamiento los bordes se mezclen suavemente y las costuras desaparezcan.

Como se observa en la Figura 9, tras aplicar los mapas de peso y la combinación ponderada se logró una panorámica en la que los bordes entre las imágenes se integran de manera suave y casi imperceptible. Las transiciones de brillo y color entre las distintas imágenes son homogéneas, lo que evita que se noten costuras o cambios abruptos en la iluminación. De esta forma, la panorámica final mantiene coherencia visual en toda su extensión, conservando los detalles de cada imagen y generando un resultado uniforme y continuo.



Figura 8: Panormapa UDESA - Izquierda vs Centro vs derecha




Figura 9: Panorama UDESA - izquierda vs centro vs derecha

4. Conclusiones

En este trabajo logramos generar una panorámica a partir de tres imágenes, consiguiendo una integración visualmente correcta y con transiciones suaves entre las distintas regiones. La aplicación de mapas de peso y la compensación de exposición ayudaron a que las costuras fueran prácticamente imperceptibles, manteniendo el detalle y la textura de cada imagen. Los resultados muestran que el enfoque utilizado permite obtener panorámicas con bordes discretos y exposición uniforme, logrando una apariencia continua a lo largo de toda la composición. En general, el proceso demostró ser efectivo para combinar múltiples imágenes de manera ordenada, conservando tanto la geometría como la calidad visual de la escena.

Referencias

- [1] Richard Szeliski, *Computer Vision: Algorithms and Applications*, Springer, 2010.
- [2] David G. Lowe, *Distinctive Image Features from Scale-Invariant Keypoints*, International Journal of Computer Vision, 2004.